

Predicción de concentraciones de PM_{2.5} en el Valle de Aburrá mediante aprendizaje automático con datos de la red SIATA

Lina Sofía Ballesteros Merchán, Alejandro Ríos Muñoz
Universidad EAFIT
Aprendizaje de Máquina Aplicado ST1631
Medellín, Colombia

I. INTRODUCCIÓN

La contaminación atmosférica constituye un problema ambiental y de salud pública. El material particulado fino PM_{2.5} está compuesto por partículas con diámetro aerodinámico inferior a 2,5 μm , cuyo tamaño favorece su penetración en zonas profundas del sistema respiratorio. Su exposición se ha relacionado con diferentes afectaciones respiratorias, por lo que resulta especialmente relevante vigilarlo en entornos urbanos [1], [2].

En el Valle de Aburrá, la configuración de un valle estrecho rodeado de montañas, junto con determinadas condiciones meteorológicas, puede dificultar la dispersión de contaminantes y favorecer su acumulación [3]. Estudios locales han asociado mayores concentraciones de PM_{2.5} con atenciones por infección respiratoria aguda, enfermedad pulmonar obstructiva crónica y asma, así como con incrementos de enfermedad respiratoria aguda en menores de cinco años y adultos de 65 años o más [1], [2].

La anticipación es relevante porque el marco colombiano no se limita a constatar la calidad del aire. La Resolución 2254 de 2017 establece que los niveles deben evaluarse por punto de monitoreo, fija para PM_{2.5} un Nivel de Prevención desde 38 $\mu\text{g}/\text{m}^3$ en 24 horas y permite declarar un nivel con anticipación cuando un modelo de pronóstico indique esa condición [4]. En consecuencia, un pronóstico localizado puede aportar información complementaria a la medición observada y resultar más pertinente que un único valor agregado para todo el valle.

El comportamiento del PM_{2.5} no depende únicamente de las emisiones, sino también de condiciones meteorológicas que intervienen en su transporte, dispersión y acumulación. Variables como la temperatura, la humedad, la precipitación y el viento han sido utilizadas para estudiar y predecir sus concentraciones [5]. En el contexto local, Baena-Salazar et al. [3] desarrollaron una red neuronal artificial para pronosticar la concentración diaria de PM_{2.5} en el Valle de Aburrá con un día de anticipación a partir de información meteorológica y de calidad del aire; en ese modelo, el PM_{2.5} del día anterior fue la entrada de mayor peso, lo que deja abierta la pregunta de cuánto añade la meteorología al historial del propio contaminante.

Este proyecto estudia si los registros públicos de SIATA per-

miten pronosticar, con un día de anticipación, la concentración media diaria de PM_{2.5} en cada estación del Valle de Aburrá, y cuánto aporta a ese pronóstico la meteorología observada.

I-A. Planteamiento del problema

El monitoreo de la calidad del aire permite conocer las concentraciones ya registradas en los distintos puntos del Valle de Aburrá, pero la gestión preventiva requiere información sobre su evolución probable. Esta brecha es especialmente relevante porque la Resolución 2254 de 2017 exige evaluar los niveles de concentración por punto de monitoreo y admite su declaración anticipada mediante pronóstico [4]. El proyecto aborda esa necesidad como un ejercicio predictivo por estación; no pretende sustituir los procedimientos oficiales de alerta.

Se busca pronosticar la media diaria de PM_{2.5} del día siguiente en cada estación a partir de información disponible hasta el final del día actual. La variable objetivo, `pm25_mean_d_plus_1`, es una concentración numérica continua expresada en $\mu\text{g}/\text{m}^3$, por lo que el problema se formula como aprendizaje supervisado de regresión. Los predictores se limitan al historial de PM_{2.5}, variables temporales y mediciones meteorológicas observadas de la estación SIATA asignada; otros contaminantes quedan fuera del alcance.

El desempeño se comparará con la persistencia, es decir, usar la media del día actual como pronóstico del siguiente. Además del error de concentración, se evaluará de forma derivada la anticipación de días con media igual o superior a 38 $\mu\text{g}/\text{m}^3$, umbral inferior del Nivel de Prevención, prestando atención a los inicios de episodio y comparando métodos con igual número de avisos, con umbrales fijados fuera del periodo de prueba. Se contrastarán modelos con y sin variables meteorológicas para medir cuánto aportan estas últimas. Los resultados podrían servir como evidencia reproducible para autoridades ambientales, investigadores y población susceptible sobre el alcance y las limitaciones de un pronóstico diario localizado.

II. TRABAJOS RELACIONADOS

Baena-Salazar et al. [3] entrenaron una red neuronal artificial para pronosticar la concentración diaria de PM_{2.5} con un día de anticipación en tres estaciones del Valle de Aburrá, entre ellas ITA-CONC, a partir de variables meteorológicas (incluida la altura de la capa de mezcla), la precipitación acumulada

de tres días y el $PM_{2.5}$ de uno a tres días antes. Validado en los primeros 91 días de 2016, el modelo alcanzó r^2 entre 0,806 (ITA-CONC) y 0,864 (MED-UNNV); el $PM_{2.5}$ del día anterior fue la entrada de mayor peso (34,2 %).

Kleine Deters et al. [5] modelaron el $PM_{2.5}$ diario de dos sitios de Quito con seis años de viento y precipitación: árboles potenciados y máquinas de soporte vectorial separaron con alta confiabilidad los niveles bajos de los altos, y la regresión fue mejor bajo condiciones meteorológicas extremas. Su modelo estima el $PM_{2.5}$ a partir de las condiciones del mismo día, por lo que no constituye un pronóstico a un día.

Parra-Sánchez et al. [2] cruzaron meteorología y $PM_{2.5}$ de SIATA (2014–2016) con atenciones en salud de Medellín, usando promedios diarios con al menos 75 % de datos válidos, y hallaron asociaciones con IRA, EPOC y asma con rezagos de 0 a 7 días.

El pronóstico diario con meteorología es, entonces, factible en el Valle de Aburrá, y el nivel del día anterior es la señal dominante. Los trabajos locales usan pocas estaciones y periodos cortos, no reportan comparación con la persistencia ni separan el aporte de la meteorología del historial del contaminante. Este proyecto evalúa ambas cosas por estación, sobre ocho años de datos abiertos.

III. PREGUNTA DE INVESTIGACIÓN

¿Es posible predecir, con un día de anticipación, la concentración media diaria de $PM_{2.5}$ por estación en el Valle de Aburrá a partir del historial del contaminante y variables temporales, y en qué medida las variables meteorológicas observadas de SIATA mejoran esa predicción frente a un pronóstico de persistencia, en error y en anticipación de días en Nivel de Prevención?

La pregunta plantea un problema de **aprendizaje supervisado de regresión**: la variable objetivo, `pm25_mean_d_plus_1`, es la concentración media diaria de $PM_{2.5}$ del día siguiente, numérica y continua, en $\mu g/m^3$. La comparación con el umbral de $38 \mu g/m^3$ del Nivel de Prevención es una lectura derivada de esa predicción numérica, no un segundo problema de clasificación; la referencia de desempeño y la regla de comparación a igual número de avisos se definieron en la Sección I-A.

IV. CARACTERIZACIÓN DE LOS DATOS

IV-A. Histórico de $PM_{2.5}$

La fuente principal es el dataset público *Material Particulado – $PM_{2.5}$* del repositorio de datos de SIATA [6], versión 4.0, publicado como 162 archivos mensuales que cubren de enero de 2013 a junio de 2026. En formato original cada fila es una hora y cada columna una estación de monitoreo: 118.296 filas y 33 códigos históricos de estación, con 30 variantes de esquema por altas y retiros de estaciones. No hay filas ni marcas de tiempo duplicadas, el índice horario no tiene huecos y no aparecen valores negativos.

Para el análisis se tomó la ventana 2018–2025 (ocho años completos) y las 16 estaciones con cobertura horaria de al menos 90 % en ese periodo (entre 92,67 % y 97,41 %). Los

datos se transformaron a formato largo, una fila por estación-hora (1.122.048 registros), y luego se agregaron por estación y día calendario, calculando la media diaria solo cuando el día tiene al menos 18 horas válidas. Resultan 46.752 combinaciones estación-día, de las cuales 1.600 (3,4 %) no reciben media por falta de horas y 44.399 cuentan con la media del día y con la del día siguiente. Los 753 registros restantes tienen media propia válida, pero su día siguiente no alcanza las 18 horas: quince corresponden al 31 de diciembre de 2025, en el borde de la ventana, y 738 a días internos sin cobertura suficiente.

No se imputaron faltantes ni se eliminaron valores extremos.

La **variable objetivo** es `pm25_mean_d_plus_1`: la concentración media de $PM_{2.5}$ de la misma estación en el día calendario siguiente, en $\mu g/m^3$, numérica y continua. Su distribución (Fig. 1) es asimétrica a la derecha, con media de 17,89, mediana de 16,33 y desviación estándar de $7,75 \mu g/m^3$, entre 2,04 y $73,67 \mu g/m^3$. Un total de 1.852 registros (4,17 %) supera el límite IQR de $34,02 \mu g/m^3$ y 1.090 (2,46 %) alcanzan el Nivel de Prevención; no se eliminan porque son los episodios que interesa anticipar. La Tabla I resume el conjunto de datos.




Fig. 1. Distribución de la variable objetivo (media diaria de $PM_{2.5}$ del día siguiente) en las 16 estaciones, 2018–2025.

Tabla I
CARACTERÍSTICAS GENERALES DEL CONJUNTO DE DATOS

Característica	Valor
Fuente	SIATA, DOI 10.83041/AUWZWT, v4.0
Periodo publicado	2013-01 a 2026-06, horario
Ventana analizada	2018–2025, 16 estaciones
Unidad de observación	estación-día
Registros estación-día	46.752 (44.399 con target)
Variable objetivo	<code>pm25_mean_d_plus_1</code>
Tipo de variable objetivo	numérica continua ($\mu g/m^3$)
Tipo de problema	regresión supervisada
Media / mediana del target	17,89 / 16,33 $\mu g/m^3$
Registros $\geq 38 \mu g/m^3$	1.090 (2,46 %)
Días sin media (<18 h válidas)	1.600 (3,4 %)
Registros duplicados	0

IV-B. Meteorología

Los predictores meteorológicos provienen de la colección *Meteorológica* del mismo repositorio, donde cada estación es un dataset independiente con registros cada minuto de temperatura, humedad relativa, presión, precipitación y velocidad y dirección del viento, más una bandera de calidad por variable [7]. A cada estación de PM_{2.5} se le asignó la estación meteorológica más cercana instalada antes de 2018 (12 estaciones distintas); 15 de las 16 quedan a 3 km o menos y la restante (MED-SCRI) a 5,8 km. Los registros minutales se agregaron a resolución horaria descartando los marcados como dudosos y exigiendo 45 minutos válidos por hora. En la mayoría de estaciones y variables la cobertura válida está entre 88 % y 98 % de las horas de la ventana; hay huecos estructurales en el viento de la estación 206 (32,8 %), la presión de la 252 (14,6 %) y la precipitación de la 229 (74,3 %), y la estación 271 no tiene datos desde agosto de 2024. Para estos casos se decidirá, por variable y estación, entre usar una estación meteorológica alternativa del mismo sitio (la 397 opera junto a la 206 desde 2019), tomar la variable de una estación vecina cuando es espacialmente suave, como la presión, o excluir la combinación con cobertura insuficiente; en ningún caso se imputará con información del periodo de prueba.

V. INSIGHTS PRELIMINARES DEL ANÁLISIS EXPLORATORIO

El análisis exploratorio completo (carga, estructura, cobertura, faltantes, duplicados, valores extremos, patrones temporales, diferencias entre estaciones, eventos de prevención y meteorología) está en el notebook que acompaña este documento, disponible junto con el código de descarga y procesamiento en el repositorio del proyecto¹. Se resumen los tres hallazgos que más respaldan la viabilidad de la pregunta.

V-A. Cobertura suficiente en las dos fuentes

Las 16 estaciones seleccionadas alcanzan entre 92,67 % y 97,41 % de cobertura horaria en 2018–2025 y producen 44.399 registros estación-día con target disponible; 15 de ellas cuentan con meteorología a 3 km o menos, con 88–98 % de horas válidas en la mayoría de variables. El volumen de PM_{2.5} permite particiones temporales por año; la estrategia frente a los faltantes meteorológicos es la descrita en la Sección IV.

V-B. Estructura temporal marcada

El promedio horario de PM_{2.5} es máximo a las 08:00 (25,79 $\mu\text{g}/\text{m}^3$) y mínimo a las 15:00 (13,48 $\mu\text{g}/\text{m}^3$), y marzo tiene el mayor promedio mensual (28,05 $\mu\text{g}/\text{m}^3$). Los días con alguna estación en Nivel de Prevención se concentran en febrero y marzo (179 de 246, Fig. 2). Estos patrones justifican evaluar variables de calendario como predictores. Los eventos son, además, muy desiguales entre años (Tabla II): 412 días-estación en 2020 y solo 4 en 2025, lo que obliga a evaluar sobre varios años de prueba.

¹<https://github.com/linaballesteros/air-quality-applied-ml>




Fig. 2. Arriba: número de estaciones en Nivel de Prevención en cada uno de los 246 días con al menos un evento. Abajo: días de evento por mes, 2018–2025.

Tabla II
DÍAS-ESTACIÓN EN NIVEL DE PREVENCIÓN ($\geq 38 \mu\text{G}/\text{M}^3$) POR AÑO, 16 ESTACIONES

Año	Registros	En prevención	Inicios de episodio
2018	5.477	140	73
2019	5.698	255	128
2020	5.677	412	89
2021	5.607	26	25
2022	5.546	59	30
2023	5.465	36	26
2024	5.520	158	63
2025	5.409	4	4
Total	44.399	1.090	438

V-C. Los episodios son locales y la persistencia es una línea base difícil de superar

En 246 días al menos una estación estuvo en Nivel de Prevención; en 110 de ellos (44,7 %) fue una sola estación y en 156 (63,4 %) fueron tres o menos (Fig. 2). Los episodios son en su mayoría fenómenos locales, lo que justifica un pronóstico por estación frente a un aviso agregado para todo el valle. Al mismo tiempo, la media diaria de hoy y la de mañana tienen correlación 0,805, y la persistencia obtiene un MAE de 3,58 $\mu\text{g}/\text{m}^3$ y precisión y recall de 0,60 como aviso de prevención con umbral 38: es una línea base competitiva. De

los 1.090 días-estación en prevención, 438 (40,2 %) son inicios de episodio, el momento en que un aviso resulta útil; como el $PM_{2.5}$ suele subir de forma gradual, el aporte de un modelo sobre la persistencia deberá demostrarse con el mismo número de avisos. Las correlaciones de rangos entre la meteorología diaria y el $PM_{2.5}$ del día siguiente son débiles pero con el signo esperado (presión $-0,16$, lluvia $-0,16$, viento $-0,07$). Estas asociaciones débiles hacen necesario evaluar empíricamente si la meteorología mejora el desempeño frente a la persistencia.

REFERENCIAS

- [1] H. Grisales-Romero, N. Montealegre, J. G. Piñeros, D. Ospina, and E. Nieto, "Relación de $PM_{2.5}$ y enfermedad respiratoria aguda en un territorio de Colombia: Modelos aditivos generalizados," *Universidad y Salud*, vol. 24, no. 1, pp. 45–54, 2022.
- [2] J. S. Parra-Sánchez, A. I. Oviedo-Carrascal, and F. O. Amaya-Fernández, "Análítica de datos: incidencia de la contaminación ambiental en la salud pública en medellín (colombia)," *Revista de Salud Pública*, vol. 22, no. 6, pp. 1–9, 2020.
- [3] D. Baena-Salazar, J. F. Jiménez, C. E. Zapata, and Á. Ramírez-Cardona, "Red neuronal artificial aplicado para el pronóstico de eventos críticos de $PM_{2.5}$ en el valle de aburrá," *DYNA*, vol. 86, no. 209, pp. 347–356, 2019.
- [4] Ministerio de Ambiente y Desarrollo Sostenible, "Resolución 2254 de 2017: Por la cual se adopta la norma de calidad del aire ambiente y se dictan otras disposiciones," Diario Oficial de la República de Colombia, 2017, consultado: 14 de septiembre de 2026. [Online]. Available: <https://www.ins.gov.co/Normatividad/Resoluciones/RESOLUCI%C3%93N%202254%20DE%202017.pdf>
- [5] J. Kleine Deters, R. Zalakeviciute, M. Gonzalez, and Y. Rybarczyk, "Modeling $PM_{2.5}$ urban pollution using machine learning and selected meteorological parameters," *Journal of Electrical and Computer Engineering*, vol. 2017, pp. 1–14, 2017.
- [6] SIATA, "Material particulado - $PM_{2.5}$," Dataset, versión 4.0, 2026, consultado el 14 de septiembre de 2026.
- [7] —, "Información de la red meteorológica," Dataset, versión 2.0, 2026, consultado el 14 de septiembre de 2026.