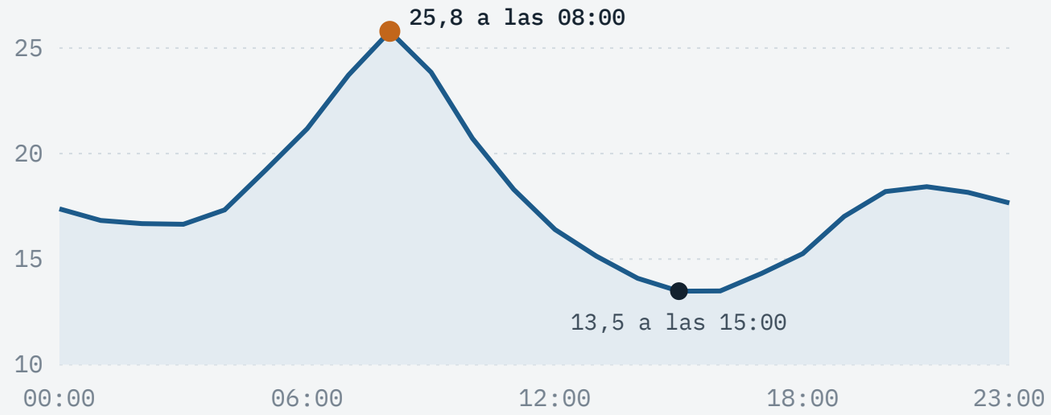
APRENDIZAJE DE MÁQUINA APLICADO · ST1631 · UNIVERSIDAD EAFIT

Pronóstico de $PM_{2.5}$ a un día por estación en el Valle de Aburrá

El $PM_{2.5}$ es el contaminante más vigilado del aire. Este trabajo busca predecir su concentración media del día siguiente en cada estación de monitoreo del Valle de Aburrá, a partir de los registros públicos de la red SIATA.



Concentración media de $PM_{2.5}$ según la hora del día, promedio de 16 estaciones entre 2018 y 2025 ($\mu g/m^3$).

Lina Sofía Ballesteros Merchán **Alejandro Ríos Muñoz**

Octubre de 2026

Por qué importa anticipar la contaminación por $PM_{2.5}$

SALUD Y GEOGRAFÍA

- El $PM_{2.5}$ es el material particulado fino, de menos de 2,5 µm; por su tamaño penetra hasta el fondo del sistema respiratorio.
- En el Valle de Aburrá se asocia con atenciones por infección respiratoria aguda, EPOC y asma.
- La geografía agrava el problema: un valle estrecho donde el contaminante se acumula cuando no logra dispersarse.

RESOLUCIÓN 2254 DE 2017 · $PM_{2.5}$, MEDIA DE 24 HORAS



- La norma exige evaluar los niveles **por punto de monitoreo**, no con un valor único para todo el valle.
- Permite **declarar un nivel de forma anticipada** si un modelo de pronóstico lo indica.
- Por eso pronosticamos por estación, con el Nivel de Prevención (**38 µg/m³**) como umbral de interés.

Con lo medido hasta hoy, ¿cuál será la media de $PM_{2.5}$ de mañana?

El monitoreo nos dice lo que ya pasó; la gestión preventiva necesita saber qué viene. Planteamos esa brecha como un problema de predicción:

- **Aprendizaje supervisado de regresión:** cada registro es una estación en un día *d*.
- **Variable objetivo:** la concentración media del día siguiente (*d*+1), en µg/m³.
- **Referencia, la persistencia:** suponer que mañana será igual a hoy. Es el rival a vencer, porque el $PM_{2.5}$ cambia poco de un día al otro.
- **Lectura como aviso:** miramos los *inicios de episodio*, el primer día que el nivel cruza 38 µg/m³.

PREGUNTA 1 · ¿LE GANAMOS A LA PERSISTENCIA?

Usando solo el historial de $PM_{2.5}$ y el calendario, ¿puede Gradient Boosting pronosticar con menos error y anticipar más días en Nivel de Prevención que la persistencia?

PREGUNTA 2 · ¿APORTA LA METEOROLOGÍA?

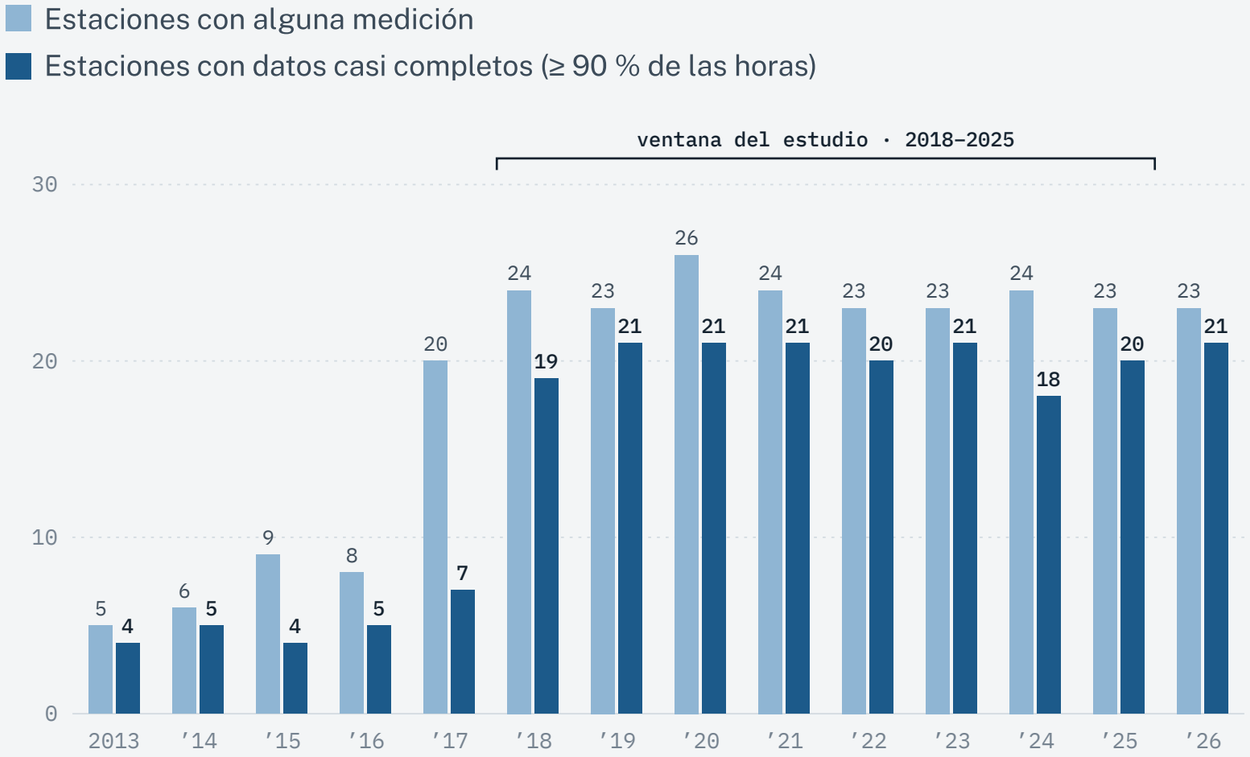
Al sumar las variables del clima medidas por SIATA, ¿mejora el pronóstico? Y según SHAP, ¿qué variables pesan más? ¿Domina el $PM_{2.5}$ del día anterior, como halló Baena-Salazar et al.?

II

Los datos

Qué mide SIATA, cómo preparamos la tabla para entrenar el modelo y qué patrones del aire descubrimos por el camino.

La red de estaciones creció con los años, y eso define el periodo de estudio



Número de estaciones de monitoreo activas cada año. El dato de 2026 llega solo hasta junio.

- **SIATA** es el sistema público de monitoreo del Valle de Aburrá: mide la calidad del aire hora a hora.
- La red creció con el tiempo: de cinco estaciones en 2013 a treinta y tres a lo largo del histórico.
- Las estaciones nuevas no tienen datos previos, así que el periodo elegido fija con cuántas podemos trabajar.
- Exigiendo ≥ 90 % de horas medidas, desde 2013 solo hay tres estaciones completas; desde 2018, dieciséis.

Por eso estudiamos **2018–2025**: dieciséis estaciones con ocho años completos.

PERIODO DE ESTUDIO	ESTACIONES COMPLETAS
2013–2025	3
2017–2025	4
2018–2025	**16**
2019–2025	17

De los archivos de SIATA a la tabla final: qué conservamos y qué dejamos fuera

$PM_{2.5}$ HORARIO

162 archivos mensuales, 2013–2026, 33 estaciones

↓

Ventana 2018–2025, cobertura ≥ 90 %
16 estaciones · **1.122.048** estación-hora

↓

Media diaria con ≥ 18 h válidas
45.152 estación-día
−1.600 días con menos de 18 h

METEOROLOGÍA

Datos minutales de las 12 estaciones asignadas (15 de 16 a ≤ 3 km)

↓

Bandera de calidad y ≥ 45 min válidos por hora
801.839 filas horarias

↓

Media diaria con ≥ 18 h por variable
presión de 0 hPa → faltante

↓

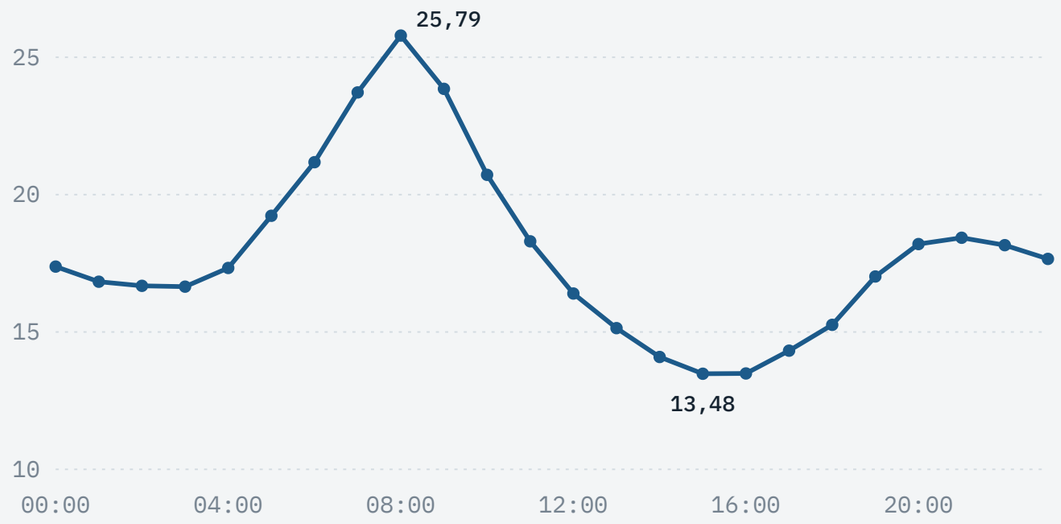
Tabla supervisada: media de hoy y de mañana
44.399 registros
−753 sin media del día siguiente

No rellenamos con valores inventados ningún dato que falte:

- Un día tiene promedio solo si tiene al menos 18 de sus 24 horas (criterio del 75 %, igual que Parra-Sánchez et al.).
- Un registro entra al modelo solo si tiene promedio de hoy y de mañana: así quedan 44.399 de 46.752.
- El **73,1 %** tiene la meteorología del día completa; el resto se conserva con huecos, que el modelo admite sin rellenar.
- Huecos conocidos (una limitación): viento de la 206, presión de la 252, lluvia de la 229 y la 271 sin datos desde 2024.

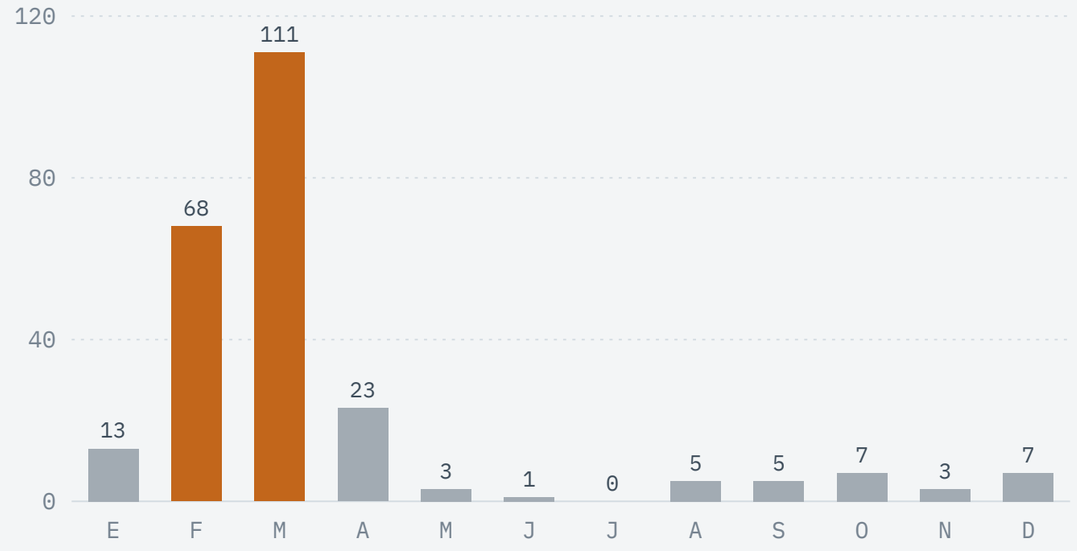
Un ciclo diario marcado y episodios concentrados en febrero y marzo

$PM_{2.5}$ PROMEDIO POR HORA DEL DÍA (µg/m³)



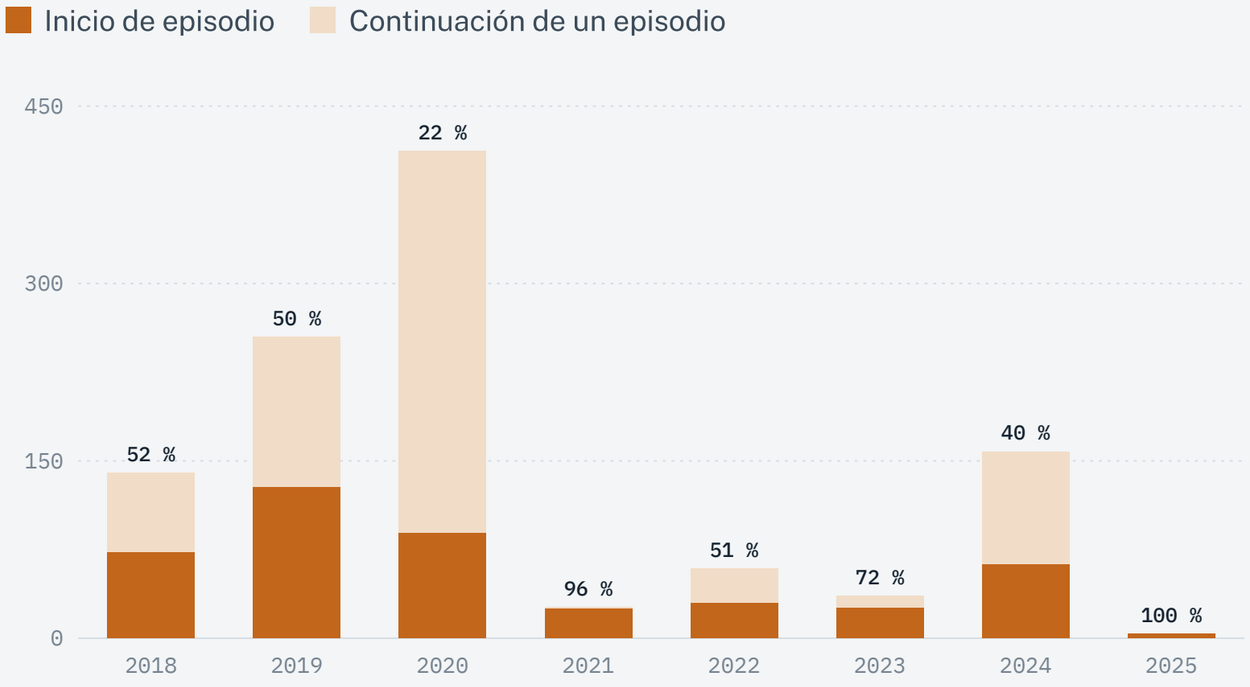
Máximo a las 08:00 con el tráfico de la mañana; mínimo a las 15:00, cuando la atmósfera se mezcla mejor.

DÍAS CON AL MENOS UNA ESTACIÓN EN NIVEL DE PREVENCIÓN, POR MES



179 de 246 días de evento caen en febrero y marzo, la transición a la temporada de lluvias.

Los episodios de contaminación varían mucho de un año a otro



Días-estación en prevención por año, 16 estaciones. Sobre cada barra, el porcentaje que son inicios.

Los años cambian no solo en número de eventos, sino en cuánto duran:

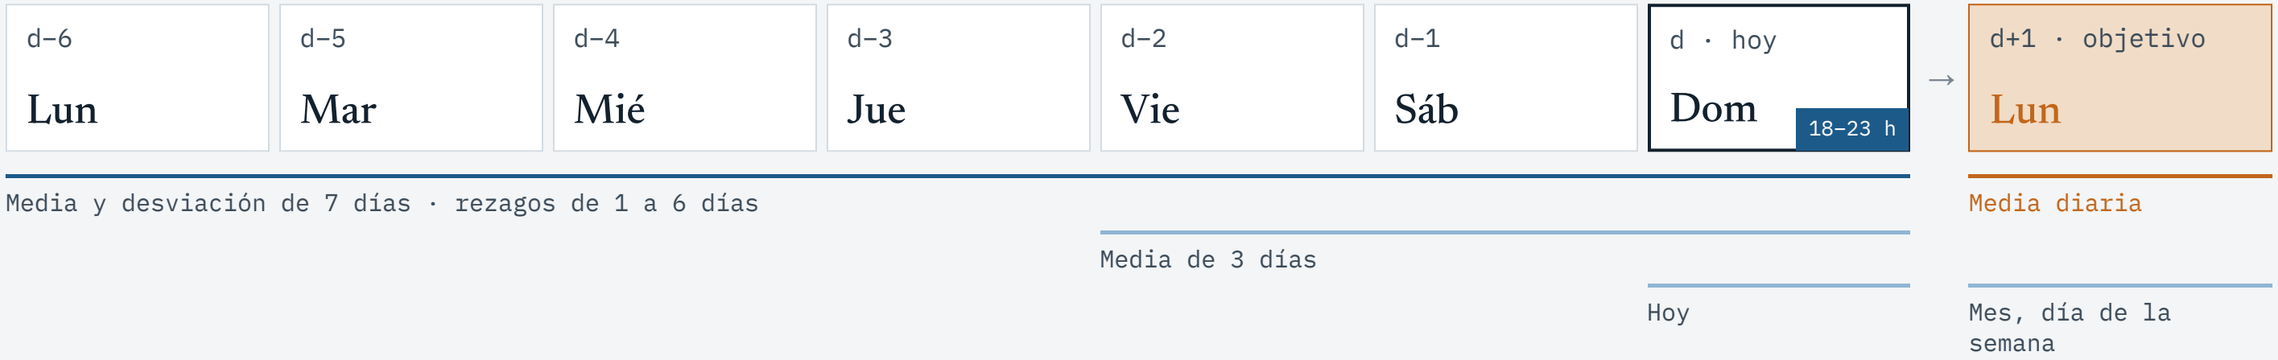
- En **2020**, 412 días en prevención pero solo 22 % fueron inicios: episodios largos, fáciles para la persistencia.
- En **2021, 2023 y 2025**, casi todo fueron días aislados, que la persistencia no anticipa. Por eso medimos en **cuatro años de prueba**.
- Los episodios son **locales**: en el 45 % de los días solo una estación llegó a prevención. Justifica pronosticar por estación.
- El $PM_{2.5}$ de hoy anticipa bien el de mañana (correlación **0,805**): la persistencia es difícil de superar.

III

Metodología

Qué información le damos al modelo, qué modelos comparamos y cómo los evaluamos sin dejar que vean el futuro.

Qué información usa el modelo: solo lo conocido hasta el final de hoy



$PM_{2.5}$ DE HOY

Media, máximo y media de 18:00 a 23:00.

VENTANAS

Rezagos de 1 a 6 días, medias de 3 y 7 días, cambio frente a ayer.

CALENDARIO

Mes y día de la semana de mañana, que se conocen de antemano.

ESTACIÓN

16 variables indicadoras (one-hot).

METEOROLOGÍA

Temperatura, humedad, presión, viento, lluvia del día y de 3 días.

Tres modelos a comparar y una forma justa de ponerlos a prueba

Persistencia (referencia)

Supone que mañana será igual a hoy. Es la regla más simple y el rival a vencer.

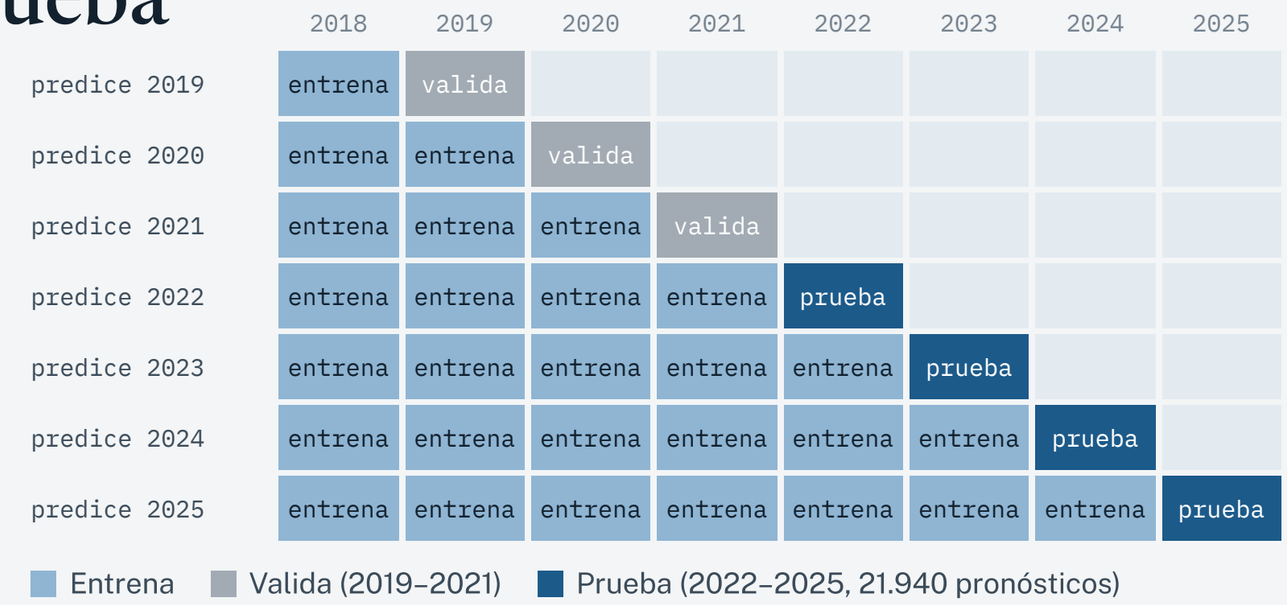
Modelo sin meteorología

Aprende del historial de $PM_{2.5}$ y del calendario. Responde si le ganamos a la persistencia (P1).

Modelo con meteorología

Añade las variables del clima del día. Al compararlo con el anterior, medimos cuánto aporta el clima (P2).

Los dos modelos usan **Gradient Boosting** (potenciación de gradiente): un método que combina muchos árboles de decisión sencillos, cada uno entrenado para corregir los errores del conjunto anterior. Elegimos esta familia porque funciona bien con datos en tabla y admite valores faltantes sin rellenarlos. Sus ajustes internos se fijaron con el conjunto de validación, nunca con el de prueba.



Como es una serie temporal, no repartimos los datos al azar. Usamos **origen móvil**:

- Cada año se pronostica entrenando solo con los años anteriores, como se haría en la práctica.
- Ningún pronóstico ve el futuro, y el resultado no depende de un único año atípico.
- 2019–2021 es validación (para ajustar el modelo); 2022–2025 es prueba, que no se miró para decidir nada.

Cuatro formas de medir, todas en los años de prueba

ERROR

MAE y R^2

Medimos cuánto se equivoca el modelo en promedio. A cada diferencia entre modelos le calculamos un intervalo de confianza del 95 % por **remuestreo en bloques** de 14 días, para no exagerar la certeza, ya que los errores de días y estaciones cercanos tienden a parecerse.

AVISOS

Comparar a igual número de avisos

Ajustamos el umbral de cada método para que avise **tantas veces como eventos hubo**, de modo que ninguno gane solo por avisar más. Sobre esa base contamos cuántos inicios de episodio logró anticipar cada uno.

INTERPRETACIÓN

SHAP

Reparte cada predicción entre sus variables de entrada, atribuyéndole a cada una cuánto empujó el resultado. La importancia global es el promedio de ese aporte en valor absoluto, expresado como porcentaje del total.

TRABAJO RELACIONADO

Réplica del estudio local previo

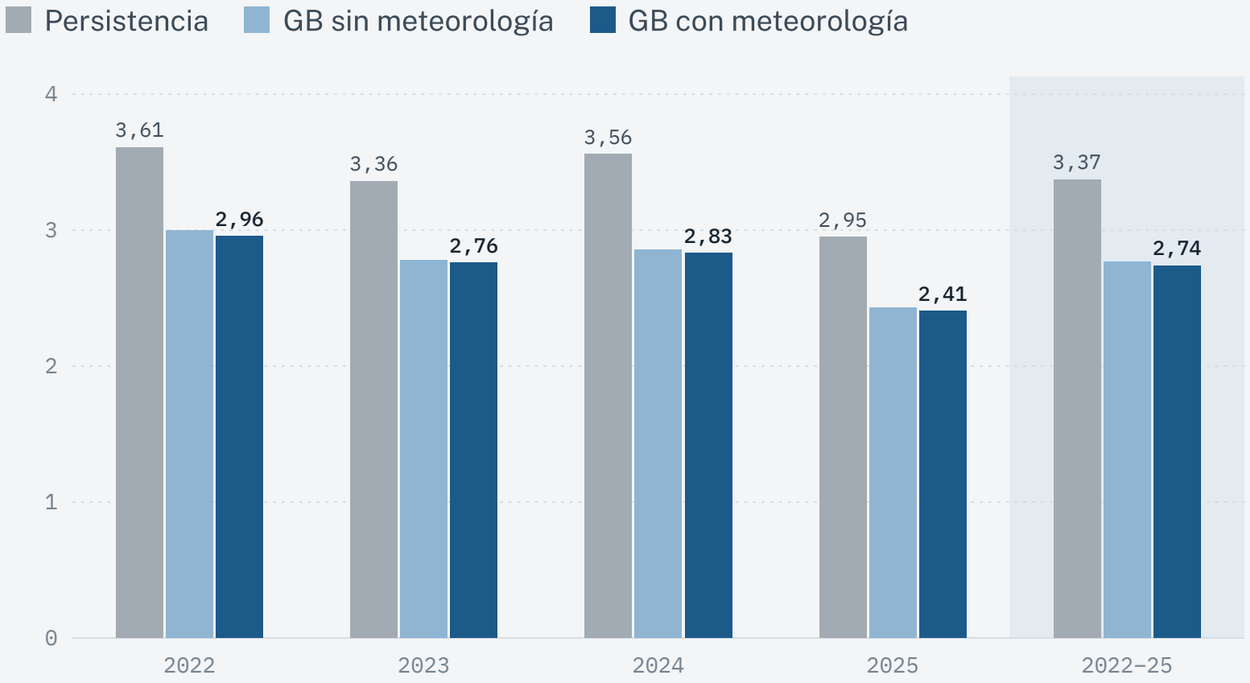
Repetimos el mismo diseño de Baena-Salazar et al.: entrenar con 2013–2015 y probar en enero–marzo de 2016, en las estaciones ITA-CONC y MED-UNNV, para comparar en igualdad de condiciones.

IV

Resultados

¿Le ganamos a la persistencia? ¿Anticipamos los episodios? ¿Qué pesa más y cómo nos comparamos con el estudio local previo?

Gradient Boosting reduce el error de la persistencia en los cuatro años



Error absoluto medio por año de prueba (µg/m³).

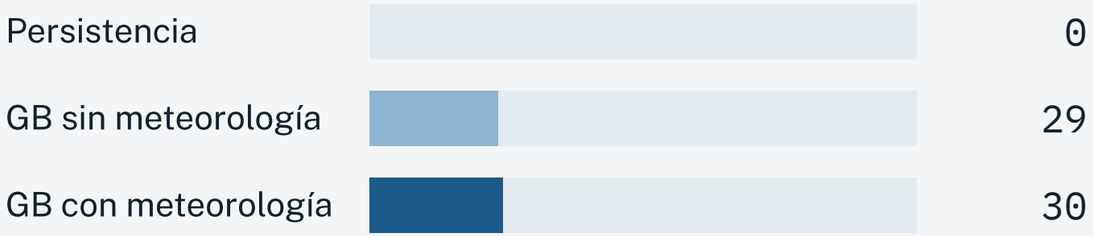
3,37 MAE persistencia

2,74 MAE GB con meteo.

- Solo con $PM_{2.5}$ y calendario, recorta el error un **18 %**: 0,61 µg/m³ menos (IC 95 %: 0,53 a 0,68, sin tocar el cero).
- El R^2 sube de 0,56 a 0,71. Esto responde que sí a la primera parte de P1.
- La meteorología suma otros **0,027 µg/m³** (IC 95 %: 0,011 a 0,047): poco, pero no es azar y aparece en 14 de 16 estaciones.
- Las dos que empeoran son las de meteorología más incompleta: el límite es la calidad del dato, no el modelo.

Con los mismos avisos, anticipa inicios que la persistencia no puede

INICIOS DE EPISODIO AVISADOS, 2022–2025 (DE 123)



A IGUAL PRESUPUESTO	AVISOS	PRECISIÓN	RECALL
Persistencia	259	0,52	0,52
GB sin meteorología	275	0,49	0,53
GB con meteorología	288	0,49	0,55

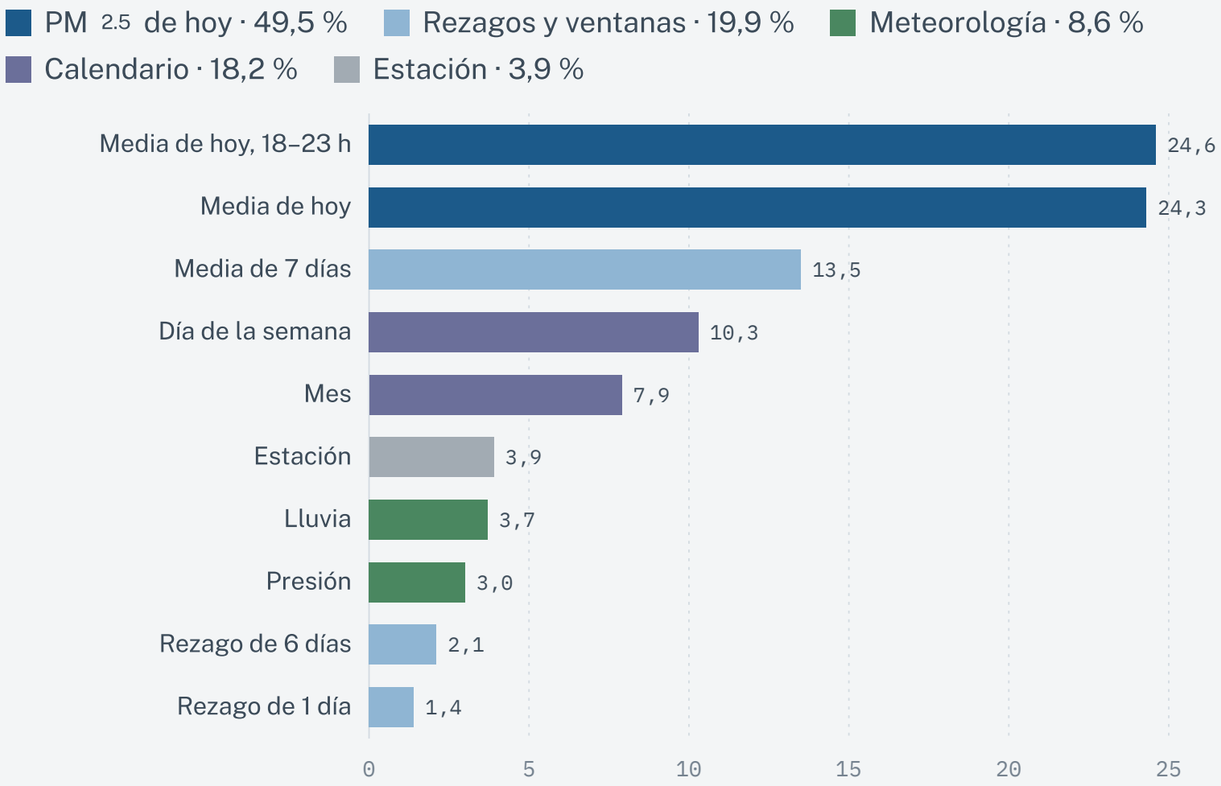
- A igual número de avisos, la precisión y el recall se parecen; lo que cambia es *qué* eventos avisan.
- La persistencia solo avisa cuando hoy ya está en prevención: **nunca anticipa un inicio**.
- Gradient Boosting, con un umbral de unos 35 µg/m^3, anticipa uno de cada cuatro inicios: ahí está su valor.

SU DEBILIDAD: LOS PICOS

DÍAS EN PREVENCIÓN	MAE	SESGO
Persistencia	5,88	-4,11
GB sin meteorología	6,90	-6,05
GB con meteorología	6,56	-5,46

En los días que ya están en prevención se equivoca más que la persistencia: subestima los picos en más de 5 µg/m^3. Es esperable al minimizar el error promedio, y es donde la meteorología más ayuda.

Lo que más pesa es el $PM_{2.5}$ del día anterior al pronosticado



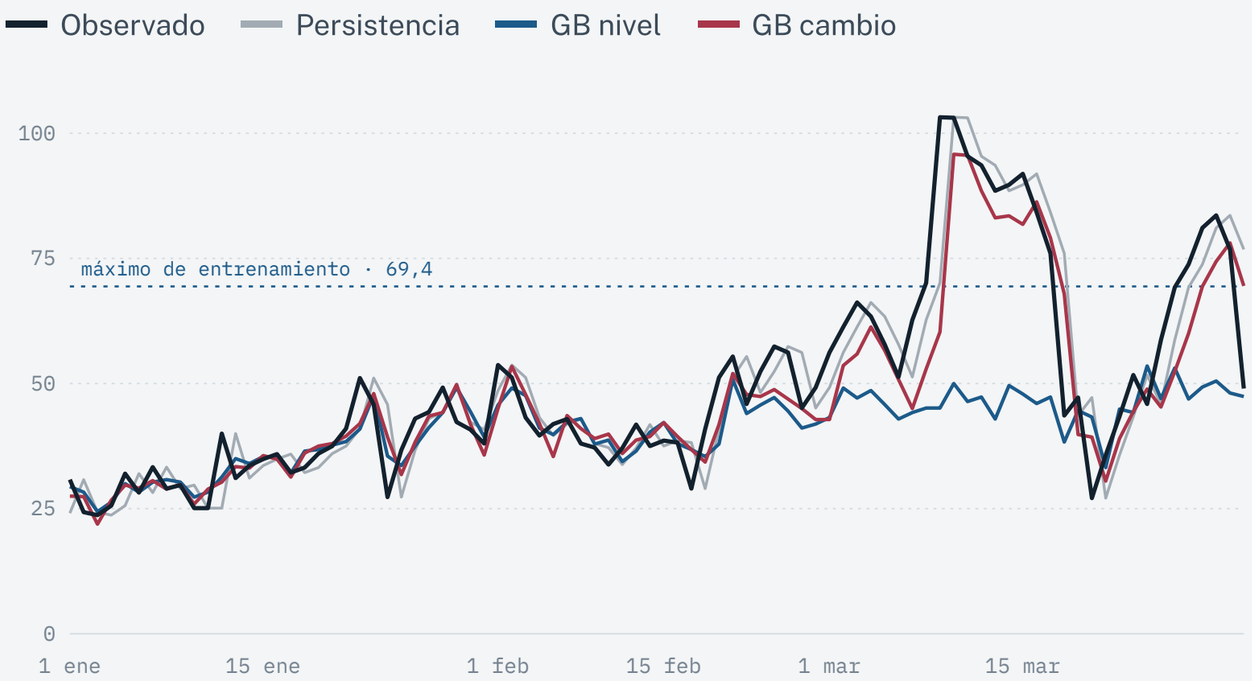
Importancia SHAP de las 10 variables con más peso, GB con meteorología, 2022–2025 (% del total).

PESO DEL $PM_{2.5}$ DEL DÍA ANTERIOR

Red neuronal de Baena-Salazar et al.	34,2 %
Nuestro modelo completo	**49,5 %**
Nuestro modelo con entradas tipo Baena	65,7 %

- El orden coincide con Baena-Salazar: en ambos, el $PM_{2.5}$ reciente es la señal dominante.
- La magnitud no es comparable: cada trabajo mide la importancia distinto y su red usaba la capa de mezcla.
- El calendario pesa porque los domingos, con menos tráfico, bajan el pronóstico.
- El **rezago de 6 días** destaca porque cae en el mismo día de la semana que mañana. La meteorología aporta el **8,6 %**, sobre todo lluvia y presión.

En su periodo, la persistencia casi iguala a la red neuronal



Media diaria de $PM_{2.5}$ (µg/m³). La línea punteada es el máximo visto al entrenar con 2013–2015.

R² / ERROR %	ITA-CONC	MED-UNNV
Red neuronal	0,81 / 18,5	0,86 / 12,4
Persistencia	**0,80 / 15,6**	**0,81 / 14,1**
GB nivel	0,73 / 16,3	0,52 / 17,0
GB cambio	0,80 / 14,2	0,82 / 11,5

- En marzo de 2016 los niveles superaron todo lo visto al entrenar; un modelo de árboles **no pronostica más alto de lo que ha visto** y falla justo ahí.
- Predecir el **cambio respecto a hoy** lo corrige, pero se probó después de ver 2016 y en 2022–2025 no ayuda.
- Por eso el modelo principal sigue prediciendo el nivel, y dejamos el cambio como trabajo futuro.

CONCLUSIONES

Un pronóstico útil, con límites claros

P1 **Sí.** Con ventanas de $PM_{2.5}$ y calendario, Gradient Boosting reduce el error de la persistencia un 18 % en los cuatro años de prueba y, a igual número de avisos, anticipa 29–30 de los 123 inicios de episodio que la persistencia no puede anticipar. Su límite son los picos, que tiende a subestimar.

P2 La meteorología observada aporta poco pero de forma estadísticamente significativa: 0,027 µg/m³ en el error promedio y 0,34 en los días en prevención, donde más hace falta. Según SHAP, el $PM_{2.5}$ del día anterior es la entrada dominante (49,5 %), igual que halló Baena-Salazar et al.

→ **Trabajo futuro:** predecir el cambio respecto a hoy, o combinarlo con el nivel, para episodios sin precedentes; alimentar el modelo con pronósticos meteorológicos en vez de observaciones; y evaluar el primer semestre de 2026, que ningún modelo ha visto.

GRACIAS

Preguntas

Código, datos de descarga y notebooks:

`github.com/linaballesteros/air-quality-applied-ml`